Análisis Multivariado de Varianza

Ejemplo: Comparación de Métodos de Enseñanza dataset LoadIris

Actividad MANOVA

Dr. Hugo García Tecocoatzi

In [1]:

```
# Bibliotecas necesarias
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import warnings
warnings.filterwarnings('ignore')

from scipy import stats
from sklearn.datasets import load_iris, load_wine, load_diabetes # Necesaria para la actividad
from scipy.stats import f_oneway
from statsmodels.multivariate.manova import MANOVA
from statsmodels.stats.multicomp import pairwise_tukeyhsd

import statsmodels.api as sm
from statsmodels.formula.api import ols

%matplotlib inline
```

In [2]:

```
# Celda 3: Cargar el dataset Iris (datos reales)
# El dataset Iris contiene mediciones de 3 especies de flores
iris = load_iris()

# Crear DataFrame
df = pd.DataFrame(iris.data, columns=iris.feature_names)
df['Especie'] = iris.target_names[iris.target]

# Renombrar columnas para claridad
df.columns = ['Longitud_Sepalo', 'Ancho_Sepalo',
              'Longitud_Petalo', 'Ancho_Petalo', 'Especie']

print(f"Forma del dataset: {df.shape}")
print(f"Especies: {df['Especie'].unique()}")
print(f"Observaciones por especie:")
print(df['Especie'].value_counts())
df.head(10)
```

```
Forma del dataset: (150, 5)
Especies: <StringArray>
['setosa', 'versicolor', 'virginica']
Length: 3, dtype: str
Observaciones por especie:
Especie
setosa        50
versicolor    50
virginica     50
Name: count, dtype: int64
```

Out[2]:

	Longitud_Sepalo	Ancho_Sepalo	Longitud_Petalo	Ancho_Petalo	Especie
0	5.1	3.5	1.4	0.2	setosa
1	4.9	3.0	1.4	0.2	setosa
2	4.7	3.2	1.3	0.2	setosa
3	4.6	3.1	1.5	0.2	setosa
4	5.0	3.6	1.4	0.2	setosa
5	5.4	3.9	1.7	0.4	setosa
6	4.6	3.4	1.4	0.3	setosa
7	5.0	3.4	1.5	0.2	setosa
8	4.4	2.9	1.4	0.2	setosa
9	4.9	3.1	1.5	0.1	setosa

In [3]:

```
#  Estadísticas descriptivas por grupo
print("ESTADÍSTICAS DESCRIPTIVAS POR GRUPO: \n")

variables = ['Longitud_Sepalo', 'Ancho_Sepalo', 'Longitud_Petalo', 'Ancho_Petalo']   # variables dependientes (se reutilizan en las demás celdas)

estadisticas = df.groupby('Especie').agg(
    {v: ['mean', 'std', 'min', 'max'] for v in variables}
).round(2)

pd.set_option('display.width', 200)
pd.set_option('display.max_columns', 20)
print(estadisticas)
```

ESTADÍSTICAS DESCRIPTIVAS POR GRUPO:

	Longitud_Sepalo				Ancho_Sepalo				Longitud_Petalo				Ancho_Petalo			
	mean	std	min	max	mean	std	min	max	mean	std	min	max	mean	std	min	max
Especie																
setosa	5.01	0.35	4.3	5.8	3.43	0.38	2.3	4.4	1.46	0.17	1.0	1.9	0.25	0.11	0.1	0.6
versicolor	5.94	0.52	4.9	7.0	2.77	0.31	2.0	3.4	4.26	0.47	3.0	5.1	1.33	0.20	1.0	1.8
virginica	6.59	0.64	4.9	7.9	2.97	0.32	2.2	3.8	5.55	0.55	4.5	6.9	2.03	0.27	1.4	2.5

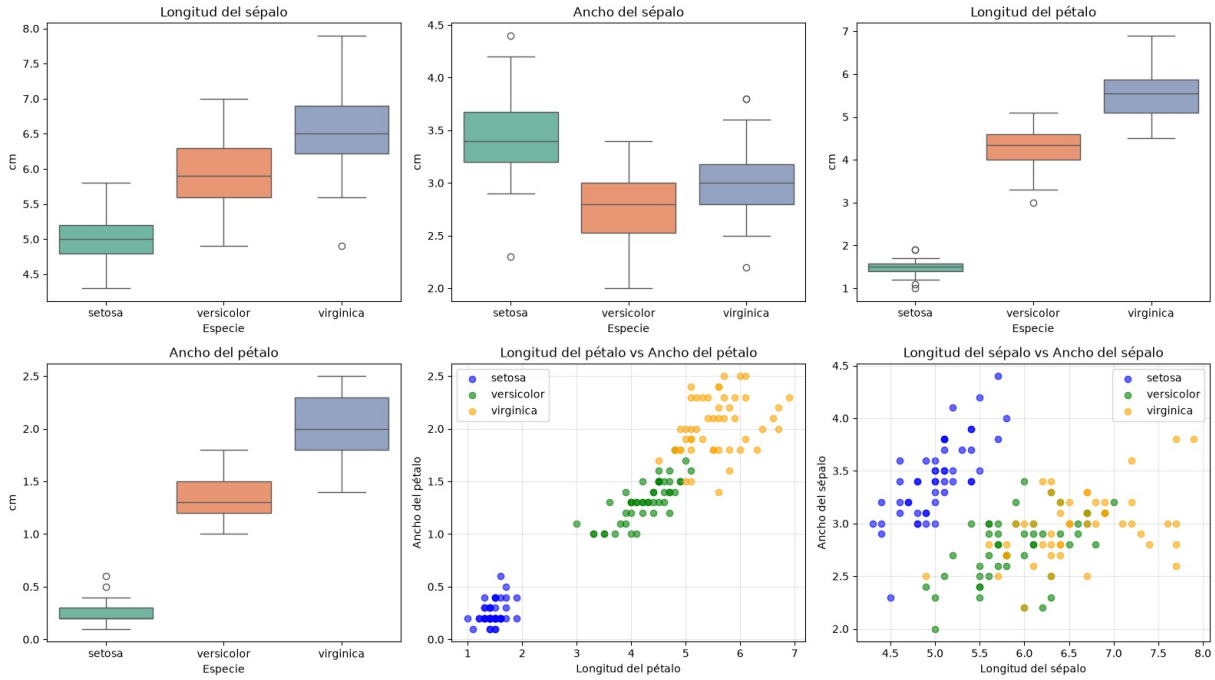
In [4]:

```
# Visualización
fig, axes = plt.subplots(2, 3, figsize=(16, 9))
titulos = {'Longitud_Sepalo': 'Longitud del sépalo', 'Ancho_Sepalo': 'Ancho del sépalo',
           'Longitud_Petalo': 'Longitud del pétalo', 'Ancho_Petalo': 'Ancho del pétalo'}

# Boxplots de las 4 variables
for ax, v in zip(axes.flatten()[:4], variables):
    sns.boxplot(x='Especie', y=v, data=df, ax=ax, palette='Set2')
    ax.set_title(titulos[v])
    ax.set_xlabel('Especie')
    ax.set_ylabel('cm')

# Scatter plots
colors = {'setosa': 'blue', 'versicolor': 'green', 'virginica': 'orange'}
for ax, (x, y) in zip(axes.flatten()[4:], [('Longitud_Petalo', 'Ancho_Petalo'), ('Longitud_Sepalo', 'Ancho_
Sepalo')]):
    for especie in df['Especie'].unique():
        subset = df[df['Especie'] == especie]
        ax.scatter(subset[x], subset[y], alpha=0.6, label=especie, color=colors[especie])
    ax.set_xlabel(titulos[x]); ax.set_ylabel(titulos[y])
    ax.set_title(f'{titulos[x]} vs {titulos[y]}')
    ax.legend(); ax.grid(True, alpha=0.3)

plt.tight_layout()
plt.show()
```



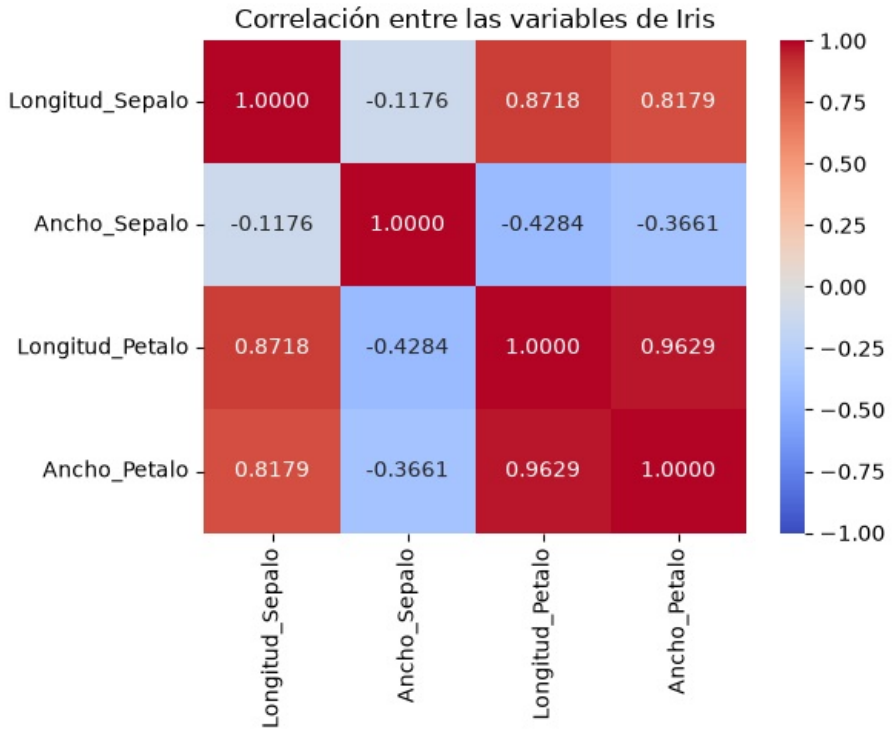
In [6]:

```
# Matriz de correlación
print("MATRIZ DE CORRELACIÓN\n")
print(df[variables].corr().round(4))

# Visualización
plt.figure(figsize=(6, 5))
sns.heatmap(df[variables].corr(),
            annot=True, cmap='coolwarm', center=0,
            vmin=-1, vmax=1, fmt='.4f')
plt.title('Correlación entre las variables de Iris')
plt.tight_layout()
plt.show()
```

```
MATRIZ DE CORRELACIÓN

                Longitud_Sepalo  Ancho_Sepalo  Longitud_Petalo  Ancho_Petalo
Longitud_Sepalo           1.0000       -0.1176           0.8718        0.8179
Ancho_Sepalo             -0.1176        1.0000          -0.4284       -0.3661
Longitud_Petalo           0.8718       -0.4284           1.0000        0.9629
Ancho_Petalo              0.8179       -0.3661           0.9629        1.0000
```



In [7]:

```
#  MANOVA - Prueba principal
print("MANOVA \n")

# Ajustar MANOVA
manova = MANOVA.from_formula('Longitud_Sepalo + Ancho_Sepalo + Longitud_Petalo + Ancho_Petalo ~ Especie', d
ata=df)
resultado = manova.mv_test()

print(resultado)
```

```
MANOVA

                  Multivariate linear model
================================================================

----------------------------------------------------------------
       Intercept         Value  Num DF  Den DF   F Value  Pr > F
----------------------------------------------------------------
          Wilks' lambda  0.0170 4.0000 144.0000 2086.7720 0.0000
         Pillai's trace  0.9830 4.0000 144.0000 2086.7720 0.0000
 Hotelling-Lawley trace 57.9659 4.0000 144.0000 2086.7720 0.0000
    Roy's greatest root 57.9659 4.0000 144.0000 2086.7720 0.0000
----------------------------------------------------------------

----------------------------------------------------------------
        Especie          Value  Num DF  Den DF   F Value  Pr > F
----------------------------------------------------------------
          Wilks' lambda  0.0234 8.0000 288.0000  199.1453 0.0000
         Pillai's trace  1.1919 8.0000 290.0000   53.4665 0.0000
 Hotelling-Lawley trace 32.4773 8.0000 203.4024  582.1970 0.0000
    Roy's greatest root 32.1919 4.0000 145.0000 1166.9574 0.0000
================================================================
```

In [8]:

```
#  Extraer resultados de los cuatro estadísticos
print("=== RESULTADOS DE LOS CUATRO ESTADÍSTICOS ===\n")

# Extraer resultados del MANOVA
resultados_mv = manova.mv_test().results['Especie']['stat']

print("Estadísticos de prueba:")
print(resultados_mv.round(4))
```

```
=== RESULTADOS DE LOS CUATRO ESTADÍSTICOS ===

Estadísticos de prueba:
                         Value Num DF     Den DF      F Value Pr > F
Wilks' lambda         0.023439      8      288.0   199.145344    0.0
Pillai's trace        1.191899    8.0      290.0    53.466489    0.0
Hotelling-Lawley trace   32.47732      8  203.40239   582.197018    0.0
Roy's greatest root     32.191929      4        145  1166.957433    0.0
```

In [10]:

```
# Interpretación de resultados
print("=== INTERPRETACIÓN DE RESULTADOS ===\n")

# Verificar significancia de cada estadístico
for estadistico in resultados_mv.index:
    if 'Pr > F' in resultados_mv.columns:
        p_valor = resultados_mv.loc[estadistico, 'Pr > F']
        valor = resultados_mv.loc[estadistico, 'Value']

        if p_valor < 0.05:
            print(f"✅ {estadistico}: Valor = {valor:.4f}, p = {p_valor:.4f} → SIGNIFICATIVO")
        else:
            print(f"❌ {estadistico}: Valor = {valor:.4f}, p = {p_valor:.4f} → NO SIGNIFICATIVO")

print("\n Conclusión:")
print("Si todos los estadísticos son significativos (p < 0.05),")
print("existe evidencia de que los métodos de enseñanza difieren")
print("en el patrón conjunto de Matemáticas y Lectura.")
```

```
=== INTERPRETACIÓN DE RESULTADOS ===

✅ Wilks' lambda: Valor = 0.0234, p = 0.0000 → SIGNIFICATIVO
✅ Pillai's trace: Valor = 1.1919, p = 0.0000 → SIGNIFICATIVO
✅ Hotelling-Lawley trace: Valor = 32.4773, p = 0.0000 → SIGNIFICATIVO
✅ Roy's greatest root: Valor = 32.1919, p = 0.0000 → SIGNIFICATIVO

 Conclusión:
Si todos los estadísticos son significativos (p < 0.05),
existe evidencia de que los métodos de enseñanza difieren
en el patrón conjunto de Matemáticas y Lectura.
```

In [11]:

```
# ANOVA univariado post-hoc (con corrección de Bonferroni)
print("=== ANOVA UNIVARIADO POST-HOC ===\n")

alpha = 0.05
alpha_bonferroni = alpha / len(variables)  # 4 variables dependientes

resumen_anova = []
for v in variables:
    print(f"ANOVA para {v}:")
    modelo = ols(f'{v} ~ Especie', data=df).fit()
    tabla = sm.stats.anova_lm(modelo, typ=2)
    print(tabla.round(4))
    ss_e = tabla.loc['Especie', 'sum_sq']; ss_r = tabla.loc['Residual', 'sum_sq']
    resumen_anova.append((v, tabla.loc['Especie', 'F'], tabla.loc['Especie', 'PR(>F)'], ss_e / (ss_e + ss_r
)))
    print()

# Corrección de bonferroni
print(f"\n Corrección de Bonferroni:")
print(f"   α original = {alpha}")
print(f"   α ajustado = {alpha_bonferroni}")

# Interpretación (se agrega η² como tamaño del efecto)
for v, F, p, eta2 in resumen_anova:
    print(f"   {v}: F = {F:.2f}, p = {p:.2e}, η² = {eta2:.3f} → {'Significativo' if p < alpha_bonferroni el
se 'No significativo'}")
```

```
=== ANOVA UNIVARIADO POST-HOC ===

ANOVA para Longitud_Sepalo:
             sum_sq     df         F  PR(>F)
Especie   63.2121    2.0  119.2645     0.0
Residual  38.9562  147.0       NaN     NaN

ANOVA para Ancho_Sepalo:
             sum_sq     df      F  PR(>F)
Especie   11.3449    2.0  49.16     0.0
Residual  16.9620  147.0    NaN     NaN

ANOVA para Longitud_Petalo:
              sum_sq     df          F  PR(>F)
Especie   437.1028    2.0  1180.1612     0.0
Residual   27.2226  147.0        NaN     NaN

ANOVA para Ancho_Petalo:
             sum_sq     df         F  PR(>F)
Especie   80.4133    2.0  960.0071     0.0
Residual   6.1566  147.0       NaN     NaN


 Corrección de Bonferroni:
   α original = 0.05
   α ajustado = 0.0125
   Longitud_Sepalo: F = 119.26, p = 1.67e-31, η² = 0.619 → Significativo
   Ancho_Sepalo: F = 49.16, p = 4.49e-17, η² = 0.401 → Significativo
   Longitud_Petalo: F = 1180.16, p = 2.86e-91, η² = 0.941 → Significativo
   Ancho_Petalo: F = 960.01, p = 4.17e-85, η² = 0.929 → Significativo
```

In [12]:

```
#  Comparaciones múltiples post-hoc (Tukey HSD)
print(" COMPARACIONES MÚLTIPLES POST-HOC (TUKEY HSD) \n")

tukey = {}
for v in variables:
    print(f"Tukey HSD para {v}:")
    tukey[v] = pairwise_tukeyhsd(df[v], df['Especie'], alpha=0.05)
    print(tukey[v])
    print()
```

```
 COMPARACIONES MÚLTIPLES POST-HOC (TUKEY HSD)

Tukey HSD para Longitud_Sepalo:
   Multiple Comparison of Means - Tukey HSD, FWER=0.05
=============================================================
  group1     group2   meandiff p-adj lower  upper  reject
-------------------------------------------------------------
    setosa versicolor     0.93   0.0 0.6862 1.1738   True
    setosa  virginica    1.582   0.0 1.3382 1.8258   True
versicolor  virginica    0.652   0.0 0.4082 0.8958   True
-------------------------------------------------------------

Tukey HSD para Ancho_Sepalo:
    Multiple Comparison of Means - Tukey HSD, FWER=0.05
=============================================================
  group1     group2   meandiff p-adj   lower   upper  reject
-------------------------------------------------------------
    setosa versicolor   -0.658    0.0 -0.8189 -0.4971   True
    setosa  virginica   -0.454    0.0 -0.6149 -0.2931   True
versicolor  virginica    0.204 0.0088  0.0431  0.3649   True
-------------------------------------------------------------

Tukey HSD para Longitud_Petalo:
   Multiple Comparison of Means - Tukey HSD, FWER=0.05
=============================================================
  group1     group2   meandiff p-adj lower  upper  reject
-------------------------------------------------------------
    setosa versicolor    2.798   0.0 2.5942 3.0018   True
    setosa  virginica     4.09   0.0 3.8862 4.2938   True
versicolor  virginica    1.292   0.0 1.0882 1.4958   True
-------------------------------------------------------------

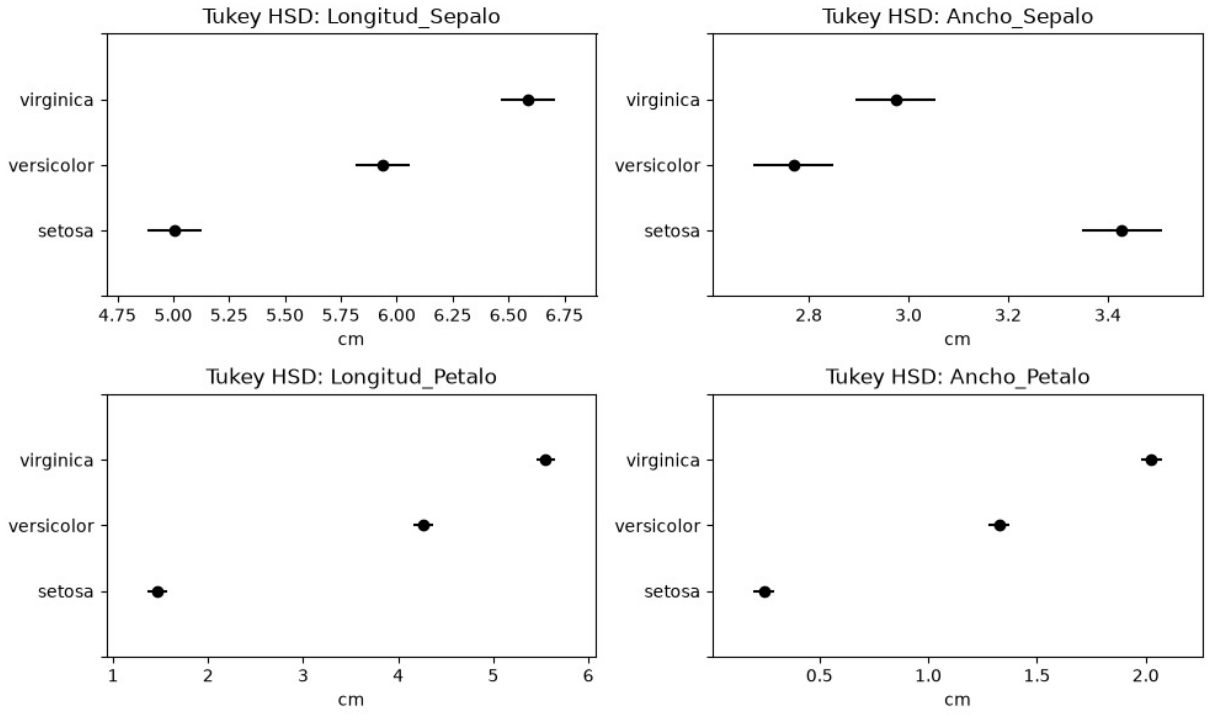
Tukey HSD para Ancho_Petalo:
   Multiple Comparison of Means - Tukey HSD, FWER=0.05
=============================================================
  group1     group2   meandiff p-adj lower  upper  reject
-------------------------------------------------------------
    setosa versicolor     1.08   0.0 0.9831 1.1769   True
    setosa  virginica     1.78   0.0 1.6831 1.8769   True
versicolor  virginica      0.7   0.0 0.6031 0.7969   True
-------------------------------------------------------------
```

In [16]:

```
# Visualización de Tukey HSD
fig, axes = plt.subplots(2, 2, figsize=(14, 9))

for ax, v in zip(axes.flatten(), variables):
    tukey[v].plot_simultaneous(ax=ax)
    ax.set_title(f'Tukey HSD: {v}')
    ax.set_xlabel('cm')


plt.tight_layout()
plt.show()
```



In [17]:

```
# Verificación de supuestos - Normalidad multivariada
print("=== VERIFICACIÓN DE SUPUESTOS ===\n")
print("--- Normalidad Multivariada ---\n")

# Test de Mardia para normalidad multivariada
def mardia_test(data, alpha=0.05):
    """
    Implementación simplificada del test de Mardia
    """
    n, p = data.shape
    mean = np.mean(data, axis=0)
    centered = data - mean
    S = np.cov(data, rowvar=False)
    S_inv = np.linalg.inv(S)

    # Asimetría multivariada
    b1p = 0
    for i in range(n):
        for j in range(n):
            b1p += (centered[i] @ S_inv @ centered[j])**3
    b1p = b1p / (n**2)

    # Curtosis multivariada
    b2p = 0
    for i in range(n):
        b2p += (centered[i] @ S_inv @ centered[i])**2
    b2p = b2p / n

    # Estadísticos de prueba
    skewness_stat = n * b1p / 6
    kurtosis_stat = (b2p - p*(p+2)) / np.sqrt(8*p*(p+2)/n)

    # p-valores
    p_skewness = 1 - stats.chi2.cdf(skewness_stat, p*(p+1)*(p+2)/6)
    p_kurtosis = 2 * (1 - stats.norm.cdf(abs(kurtosis_stat)))

    return {
        'Skewness statistic': skewness_stat,
        'Skewness p-value': p_skewness,
        'Kurtosis statistic': kurtosis_stat,
        'Kurtosis p-value': p_kurtosis
    }

# Aplicar test por grupo
for metodo in df['Especie'].unique():
    subset = df[df['Especie'] == metodo][variables].values
    print(f"Método {especie}:")
    resultado = mardia_test(subset)
    for key, value in resultado.items():
        print(f"  {key}: {value:.4f}")

    if resultado['Skewness p-value'] > 0.05 and resultado['Kurtosis p-value'] > 0.05:
        print("  ✅ Normalidad multivariada aceptable")
    else:
        print("  ⚠️ Posible violación de normalidad multivariada")
    print()
```

```
=== VERIFICACIÓN DE SUPUESTOS ===

--- Normalidad Multivariada ---

Método virginica:
  Skewness statistic: 24.1551
  Skewness p-value: 0.2357
  Kurtosis statistic: 0.7587
  Kurtosis p-value: 0.4480
  ✅ Normalidad multivariada aceptable

Método virginica:
  Skewness statistic: 23.7039
  Skewness p-value: 0.2556
  Kurtosis statistic: -1.0342
  Kurtosis p-value: 0.3010
  ✅ Normalidad multivariada aceptable

Método virginica:
  Skewness statistic: 24.7257
  Skewness p-value: 0.2121
  Kurtosis statistic: -0.3384
  Kurtosis p-value: 0.7350
  ✅ Normalidad multivariada aceptable
```

In [18]:

```
#  Verificación de supuestos - Homogeneidad de covarianzas (Box's M)
print(" Homogeneidad de Matrices de Covarianza (Box's M) \n")

def box_m_test(data, groups):
    """
    Implementación del test M de Box
    """
    group_names = groups.unique()
    k = len(group_names)
    p = data.shape[1]

    # Tamaños de muestra
    ns = [len(data[groups == g]) for g in group_names]
    n_total = sum(ns)

    # Matrices de covarianza por grupo
    covs = []
    for g in group_names:
        subset = data[groups == g]
        covs.append(np.cov(subset, rowvar=False))

    # Covarianza pooled
    pooled_cov = sum([(n-1) * cov for n, cov in zip(ns, covs)]) / (n_total - k)

    # Estadístico M
    M = (n_total - k) * np.log(np.linalg.det(pooled_cov))
    for n, cov in zip(ns, covs):
        M -= (n - 1) * np.log(np.linalg.det(cov))

    # Factor de corrección
    c = (2 * p**2 + 3 * p - 1) / (6 * (p + 1) * (k - 1))
    c *= sum([1/(n-1) for n in ns]) - 1/(n_total - k)

    # Estadístico de prueba
    chi2_stat = M * (1 - c)

    # Grados de libertad
    df = p * (p + 1) * (k - 1) / 2

    # p-valor
    p_value = 1 - stats.chi2.cdf(chi2_stat, df)

    return {
        'M statistic': M,
        'Chi-square': chi2_stat,
        'df': df,
        'p-value': p_value
    }

# Aplicar Box's M
resultado_box = box_m_test(df[variables], df['Especie'])
print("Resultados del test M de Box:")
for key, value in resultado_box.items():
    print(f"  {key}: {value:.4f}")

if resultado_box['p-value'] > 0.05:
    print("\n✓ No se rechaza H₀: Las matrices de covarianza son homogéneas")
else:
    print("\n⚠ Se rechaza H₀: Posible violación de homogeneidad de covarianzas")
    print("   → Considerar usar Pillai's Trace (más robusto)")
```

```
 Homogeneidad de Matrices de Covarianza (Box's M)

Resultados del test M de Box:
  M statistic: 146.6632
  Chi-square: 140.9430
  df: 20.0000
  p-value: 0.0000

⚠ Se rechaza H₀: Posible violación de homogeneidad de covarianzas
   → Considerar usar Pillai's Trace (más robusto)
```

In [ ]:

```
#  Preguntas de análisis
print(" PREGUNTAS DE ANÁLISIS:")
print("\n1. ¿Cuál de los cuatro estadísticos MANOVA es más apropiado y por qué?")
print("2. ¿Qué variable dependiente contribuye más a las diferencias entre grupos?")
print("3. ¿Qué pares de grupos son significativamente diferentes?")
print("4. ¿Se cumplen los supuestos del MANOVA? ¿Qué implicaciones tiene?")
print("5. ¿Cómo se relacionan los resultados del LDA con los del MANOVA?")
```

```
 PREGUNTAS DE ANÁLISIS:

1. ¿Cuál de los cuatro estadísticos MANOVA es más apropiado y por qué?
2. ¿Qué variable dependiente contribuye más a las diferencias entre grupos?
3. ¿Qué pares de grupos son significativamente diferentes?
4. ¿Se cumplen los supuestos del MANOVA? ¿Qué implicaciones tiene?
5. ¿Cómo se relacionan los resultados del LDA con los del MANOVA?
```

1. Como los cuatro estadísticos salen de los mismo eigenvalores de $E^{-1}H$ (32.19 y 0.29) se debe de elegir por el supuesto de homogeneidad de covarianzas que no se cumple en otros pero Pillai es el más robusto ante violaciones ya que ofrece la mejor protección sin perder potencia.
2. La `longitud del pétalo` es la variable más contribuyente seguida por el `ancho del pétalo` por muy poco por el ancho del pétalo porque el criterio por el cual se diferencian y por tan pequeño es la varianza explicada (η^2) en la cual la `longitud del pétalo` consiguió explicar una varianza entre especies del 94.1% (η^2=0.941)
3. Los pares más significativos fueron seleccionadas con Pillai y la corrección de Bonferroni donde Tukey HSD ayuda a confirmarlo variable por variable, por ello se seleccionaron `setosa-versicolor` , `setosa-virginica` y `versicolor-virginica` los cuales obtuvieron un p_ajustado muy pequeño:

- `setosa-versicolor` : $p_{ajustado} = 8e^{-67}$
- `setosa-virginica` : $p_{ajustado} = 1.3e^{-79}$
- `versicolor-virginica` : $p_{ajustado} = 2.9e^{-30}$

4. Los supuestos se cumplen parcialmente por ejemplo:

- Normalidad multivariada: se cumple en tres de las especies.
- Homogeneidad: No se cumplen.
- Independencia y tamaño de muestra: observaciones independientes por grupo, mayor que el número de variables.
- Multicolinealidad: Existe correlación alta entre la longitud y ancho del pétalo (r=0.963) y entre la longitud del sépalo y la longitud del pétalo (r=0.872). Esto implica o muestra que Box's M es muy sensible, sobre todo con varias variables y muestras de este tamaño; así que puede rechazar ante diferencias moderadas . Como los grupos son de igual tamaño, el MANOVA es razonable tolerante, y por eso se una Pillai. Además el efecto es muy grande, por lo que la conclusión de que las especies difieren no se ve comprometida.

5. Al ser el mismo cálculo visto de ángulos diferentes se comprueba numéricamente que los eigenvalores ($E^{-1}H$ son 32.19 y 0.29) que equivalen al 99.12% y 0.88% lo que muestra ser idéntica a la varianza explicada por LD1 y LD2.